

10 ARIMA-Modelle für nicht-stationäre Zeitreihen

In diesem Abschnitt untersuchen wir einige praktische Aspekte bei der Wahl eines geeigneten Modells für eine beobachtete Zeitreihe X_1, \dots, X_n . Falls

- die Reihe ein stationäres Verhalten zeigt (Grafik) und
- die Autokovarianzen schnell genug abklingen,

so legt man i.A. ein ARMA(p, q)-Modell zugrunde.

Falls nicht, versucht man, durch geeignete Transformation (z.B. Differenzenbildung) zu einer ARMA(p, q)-Reihe zu kommen.

Definition 10.1. (*ARIMA(p, d, q)-Reihe*) Für $d \in \mathbb{N}_0$ heißt $\{X_n\}_{n \in \mathbb{Z}}$ eine ARIMA(p, d, q)-Reihe, falls die Zeitreihe $\{Y_n\}_{n \in \mathbb{Z}}$ mit $Y_n = (1 - B)^d X_n$, $n \in \mathbb{Z}$, eine kausale ARMA(p, q)-Reihe bildet.
 $\left[\text{AutoRegressive Integrierte Moving Average-Zeitreihe} \right].$

D.h., eine ARIMA(p, d, q)-Reihe genügt der Differenzengleichung

$$(10.1) \quad a^*(B) X_n = a(B)(1 - B)^d X_n = b(B) e_n, \quad n \in \mathbb{Z},$$

mit $\{e_n\} \stackrel{\mathcal{D}}{\sim} WN(0, \sigma^2)$, dem Backward-Shift-Operator B und Polynomen

$$\begin{aligned} a^*(z) &= a(z)(1 - z)^d = (1 - a_1 z - \dots - a_p z^p)(1 - z)^d, \quad a_p \neq 0, \\ b(z) &= 1 + b_1 z + \dots + b_q z^q \end{aligned}, \quad b_q \neq 0,$$

wobei $a(z) \neq 0$ für $|z| \leq 1$ (Kausalität). Das Polynom $a^*(\cdot)$ besitzt also eine d -fache Nullstelle bei $z = 1$.

Bemerkung 10.1.

- a) Bei $d \geq 1$ kann ein polynomialer Trend der Ordnung $d - 1$ zu $\{X_n\}$ addiert werden, ohne die Gleichungen (10.1) zu verletzen. Daher gilt:
 $\{X_n\}$ ist stationär $\iff d = 0$.
- b) EX_n und $Cov(X_n, X_m)$ sind durch (10.1) nicht eindeutig festgelegt.
- c) Für eine Vorhersage werden zusätzliche Bedingungen an $\{X_n\}$ benötigt (s.u.).

Beispiel 10.1. $\{X_n\}$ ist ARIMA(1, 1, 0)-Reihe, falls für $|\alpha| < 1$ gilt:

$$(1 - \alpha B)(1 - B) X_n = e_n, \quad \text{d.h.}$$

$$Y_n = (1 - B)X_n = \sum_{j=0}^{\infty} \alpha^j e_{n-j}, \quad n \in \mathbb{Z},$$

wobei $\{e_n\} \xrightarrow{D} WN(0, \sigma^2)$. Folglich:

$$X_n = X_0 + \sum_{j=1}^n Y_j, \quad n \in \mathbb{N}, \quad \text{sowie} \quad X_{-n} = X_0 - \sum_{j=0}^{n-1} Y_{-j}, \quad n \in \mathbb{N}.$$

Typisch für ARIMA-Zeitreihen: Es gibt langsam abklingende positive (oder oszillierende) Autokovarianzen.

Ferner: Es werden nur spezielle Nicht-Stationaritäten modelliert.

Wichtig: Identifikation der Modellordnungen (p, q und d).

Oft gelingt eine angemessene Modellierung erst nach vorheriger Transformation, z.B. Box-Cox (1964)-Transformationen:

$$f_{\lambda}(X_j) = \begin{cases} \frac{1}{\lambda}\{X_j - 1\} & , \quad X_j \geq 0 \quad (\lambda > 0) \\ \ln X_j & , \quad X_j > 0 \quad (\lambda = 0) . \end{cases} \quad \text{bzw.}$$

Identifikation: Sei $\{X_j\}$ trendbereinigte, ggf. transformierte Zeitreihe, für die ein ARMA(p, q)-Modell angepasst werden soll.

Man beachte: Es besteht die Gefahr der Überanpassung (“Overfitting”), z.B. können 100 beobachtete Werte (etwa) einer Zeitreihe $Y_j = a + b_j + \varepsilon_j$ ($j = 1, \dots, 100$) perfekt durch ein Polynom 99-sten Grades angepasst werden, das aber offenbar das Modell weit verfehlt.

Daher: Anpassungskriterien, die “Overfitting” verhindern sollen.

FPE-Kriterium (Akaike, 1969) [Minimiere “Final Prediction Error”]:

FPE: (Geschätzter) 1-Schritt-Vorhersagefehler einer von $\{X_1, \dots, X_n\}$ unabhängigen Realisation, etwa $\{Y_1, \dots, Y_n\}$, derselben Zeitreihe.

Sei z.B. $\{X_1, \dots, X_n\}$ Abschnitt einer kausalen AR(p)-Reihe und $\{Y_1, \dots, Y_n\}$ unabhängig von $\{X_1, \dots, X_n\}$ mit derselben Struktur; ferner seien $\hat{a}_1, \dots, \hat{a}_p$ die

ML-Schätzer von a_1, \dots, a_p , basierend auf X_1, \dots, X_n . Betrachte den (geschätzten) 1-Schritt-Vorhersagefehler

$$E(Y_{n+1} - \hat{a}_1 Y_n - \dots - \hat{a}_p Y_{n+1-p})^2.$$

Mit $X^{(n)} = (X_1, \dots, X_n)^\top$, $Y^{(n,p)} = (Y_n, \dots, Y_{n+1-p})^\top$, $a = (a_1, \dots, a_p)^\top$, $\hat{a} = (\hat{a}_1, \dots, \hat{a}_p)^\top$ erhält man:

$$\begin{aligned} E(Y_{n+1} - \hat{a}^\top Y^{(n,p)})^2 &= E(Y_{n+1} - a^\top Y^{(n,p)} - (\hat{a} - a)^\top Y^{(n,p)})^2 \\ &\stackrel{\text{Kausalität}}{=} \sigma^2 + E(E\{(\hat{a} - a)^\top Y^{(n,p)} Y^{(n,p)\top} (\hat{a} - a) \mid X^{(n)}\}) \\ &\stackrel{\substack{X^{(n)}, Y^{(n,p)} \\ \text{unabhängig}}}{=} \sigma^2 + E\{(\hat{a} - a)^\top \Gamma_p (\hat{a} - a)\} \quad \text{mit} \quad \Gamma_p = (\gamma(j-k))_{j,k=1,\dots,p}. \end{aligned}$$

Bei $\{e_n\} \stackrel{\mathcal{D}}{\sim} IID(0, \sigma^2)$ gilt (vgl. Brockwell & Davis (1991), Theorem 8.1.1):

$$\begin{aligned} \sqrt{n}(\hat{a} - a) &\stackrel{\mathcal{D}}{\approx} N(\underline{0}, \sigma^2 \Gamma_p^{-1}) \quad \text{und daher} \\ n(\hat{a} - a)^\top \Gamma_p (\hat{a} - a) &\stackrel{\mathcal{D}}{\approx} \sigma^2 \mathcal{X}_p^2, \quad \text{d.h.} \\ E((\hat{a} - a)^\top \Gamma_p (\hat{a} - a)) &\approx \sigma^2 \frac{p}{n}, \quad \text{also} \\ E(Y_{n+1} - \hat{a}_1 Y_n - \dots - \hat{a}_p Y_{n+1-p})^2 &\approx \sigma^2 \left(1 + \frac{p}{n}\right). \end{aligned}$$

Ersetzt man σ^2 durch die ML-Schätzung $\hat{\sigma}^2$ und beachtet (vgl. Brockwell & Davis (1991), § 8.9)

$$n \hat{\sigma}^2 \stackrel{\mathcal{D}}{\approx} \sigma^2 \mathcal{X}_{n-p}^2, \quad \text{d.h.} \quad \frac{n \hat{\sigma}^2}{n-p} \quad \text{asymptotisch erwartungstreue},$$

so motiviert dies den Ansatz: Minimiere

$$FPE := \frac{n \hat{\sigma}^2}{n-p} \left(1 + \frac{p}{n}\right) = \hat{\sigma}^2 \frac{n+p}{n-p}.$$

Allgemeiner anwendbar ist das

AIC-Kriterium (Akaike 1973) [“Akaike’s Information Criterion”]:

Es basiert auf der Kullback-Leibler-Information (dem Kullback-Leibler-Index) einer W-Dichte $f(\cdot; \vartheta)$ bzgl. einer anderen $f(\cdot; \vartheta_0)$, d.h. auf

$$I(\vartheta | \vartheta_0) := \int -2 \log(f(x; \vartheta)) f(x; \vartheta_0) dx = E_{\vartheta_0} \{-2 \log(f(X; \vartheta))\}.$$

Die Jensen’sche Ungleichung liefert für die Kullback-Leibler-Diskrepanz $d(\vartheta | \vartheta_0) := I(\vartheta | \vartheta_0) - I(\vartheta_0 | \vartheta_0)$:

$$d(\vartheta|\vartheta_0) \geq -2 \log \int \frac{f(x, \vartheta)}{f(x, \vartheta_0)} f(x, \vartheta_0) dx = 0,$$

wobei “=” genau dann gilt, wenn $P_\vartheta^X = P_{\vartheta_0}^X$.

Seien $\{X_1, \dots, X_n\}$ Abschnitt einer kausalen ARMA(p, q)-Reihe und $\{Y_1, \dots, Y_n\}$ unabhängig von $\{X_1, \dots, X_n\}$ mit derselben Struktur. Analog zum FPE betrachtet man die (geschätzte) Kullback-Leibler-Information

$$(10.2) \quad E_{a,b;\sigma^2} \{ -2 \log f(Y; \hat{a}, \hat{b}, \hat{\sigma}^2) \},$$

wobei $X = (X_1, \dots, X_n)^\top$, $Y = (Y_1, \dots, Y_n)^\top$, \hat{a} , \hat{b} , $\hat{\sigma}^2$ die Schätzer für die entsprechende Gauß'sche ARMA(p, q)-Reihe bezeichnen (vgl. (9.13)–(9.14)). Mit $S(a, b) = S_X(a, b)$ aus § 9 erhält man für die log-Likelihoodfunktion:

$$\begin{aligned} -2 \log L_Y(\hat{a}, \hat{b}, \hat{\sigma}^2) &= -2 \log L_X(\hat{a}, \hat{b}, \hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} S_Y(\hat{a}, \hat{b}) - n \\ [\text{beachte: }] \quad \frac{1}{n} S_X(\hat{a}, \hat{b}) &= \hat{\sigma}^2, \quad \text{folglich} \\ E_{a,b,\sigma^2} \{ -2 \log f(Y; \hat{a}, \hat{b}, \hat{\sigma}^2) \} &= E_{a,b,\sigma^2} \{ -2 \log L_X(\hat{a}, \hat{b}, \hat{\sigma}^2) \} + E_{a,b,\sigma^2} \left\{ \frac{S_Y(\hat{a}, \hat{b})}{\hat{\sigma}^2} \right\} - n. \end{aligned}$$

Man kann zeigen, dass

$$E_{a,b,\sigma^2} S_Y(\hat{a}, \hat{b}) \stackrel{\text{Normalapprox.}}{\approx} \sigma^2 (n + p + q)$$

sowie $S_Y(\hat{a}, \hat{b})$ asymptotisch unabhängig ist von $\hat{\sigma}^2$. Daher:

$$\begin{aligned} (10.3) \quad E_{a,b,\sigma^2} \left\{ \frac{S_Y(\hat{a}, \hat{b})}{\hat{\sigma}^2} \right\} - n &\approx \sigma^2 (n + p + q) E_{a,b,\sigma^2} \left(\frac{1}{\hat{\sigma}^2} \right) - n \\ &\stackrel{\text{B&D}}{\approx} \sigma^2 (n + p + q) \left(\sigma^2 \frac{n - p - q - 2}{n} \right)^{-1} - n = \frac{2(p + q + 1)n}{n - p - q - 2} \end{aligned}$$

\implies

$AICC(\hat{a}, \hat{b}) := -2 \log L_X(\hat{a}, \hat{b}; \frac{S_X(\hat{a}, \hat{b})}{n}) + \frac{2(p + q + 1)n}{n - p - q - 2}$

ist asymptotisch erwartungstreuer Schätzer der (geschätzten) Kullback-Leibler-Information in (10.2), falls a, b, σ^2 bzw. p, q die zutreffenden Parameterwerte sind. Wähle daher p, q derart, dass $AICC(\hat{a}, \hat{b})$ minimiert wird.

[Akaike's Information Criterion Corrected]

Das “Akaike Information Criterion”

$$AIC(\hat{a}, \hat{b}) := -2 \log L_X(\hat{a}, \hat{b}; \frac{S_X(\hat{a}, \hat{b})}{n}) + 2(p+q+1)n$$

benutzt eine andere Approximation in (10.3), kann aber ansonsten entsprechend verwendet werden.

Weitere Modelldiagnose:

Da die gewichteten Innovationen $W_j = (X_j - \hat{X}_j) / \sqrt{r_{j-1}}$ mit $r_{j-1} = E(X_j - \hat{X}_j)^2 / \sigma^2$ ($j = 1, \dots, n$) paarweise orthogonal sind, mit $EW_j = 0$, $EW_j^2 = \sigma^2$, also den Abschnitt einer $WN(0, \sigma^2)$ -Reihe bilden, sollten sich auch die (so genannten) Residuen

$$(10.4) \quad \hat{W}_j = \frac{X_j - \hat{X}_j(\hat{a}, \hat{b})}{\sqrt{r_{j-1}(\hat{a}, \hat{b})}}, \quad j = 1, 2, \dots,$$

näherungsweise wie ein weißes Rauschen $WN(0, \hat{\sigma}^2)$ verhalten.

Eine andere mögliche Wahl der Residuen ist:

$$\hat{e}_j = \hat{b}^{-1}(B) \hat{a}(B) X_j, \quad j = 1, \dots, n,$$

wobei $\hat{a}(z) := 1 - \hat{a}_1 z - \dots - \hat{a}_p z^p$, $\hat{b}(z) = 1 + \hat{b}_1 z + \dots + \hat{b}_q z^q$ und $X_j := 0$, falls $j \leq 0$.

Zu Tests auf Vorliegen eines weißen Rauschens vgl. Brockwell & Davis (1991), § 9.4.

Vorhersage von ARIMA-Zeitreihen:

I.A. sind die E.W. EX_j und 2. Momente $EX_j X_{j+k}$ einer ARIMA(p, d, q)-Reihe nicht durch die Modellgleichungen (10.1) eindeutig festgelegt.

Sei z.B. $\{Y_j\}_{j=1,2,\dots}$ eine zentrierte, kausale ARMA(p, q)-Reihe und

$$X_j = X_0 + \sum_{\ell=1}^j Y_{\ell} \quad (j = 1, 2, \dots)$$

mit einer quadratintegrierbaren ZV. X_0 , so bildet $\{X_j\}_{j=0,1,\dots}$ eine ARIMA($p, 1, q$)-Reihe mit E.W. $EX_j = EX_0$ und Autokovarianzen, die von $Var(X_0)$ und den Kovarianzen $Cov(X_0, Y_j)$ abhängen.

Beste lineare Vorhersage: Sei $\mathcal{M}_n = [\{X_0, X_1, \dots, X_n\}] = [\{X_0, Y_1, \dots, Y_n\}]$, so ergibt sich:

$$\hat{X}_{n+1} = P_{\mathcal{M}_n} (X_0 + Y_1 + \dots + Y_{n+1}) = X_n + P_{\mathcal{M}_n} Y_{n+1},$$

wobei letztere Projektion von EX_0Y_j ($j = 1, \dots, n+1$) und EX_0^2 abhängt.

Sind X_0 und die $\{Y_j\}$ unkorreliert, so gilt:

$$P_{[\{X_0, Y_1, \dots, Y_{n+1}\}]} Y_{n+1} = P_{[\{Y_1, \dots, Y_n\}]} Y_{n+1},$$

d.h., es genügt die Kenntnis der acv.f. von $\{Y_j\}$ für die Vorhersage von $\{X_j\}$.

Allgemeiner Fall: Die beobachtete Zeitreihe $\{X_j\}_{j=1,2,\dots}$ genüge der Differenzengleichung

$$(10.5) \quad (1 - B)^d X_j = Y_j, \quad j = 1, 2, \dots,$$

wobei $\{Y_j\}$ eine kausale ARMA(p, q)-Reihe sei und B der Backward-Shift-Operator.

Annahme: $\{X_{1-d}, X_{2-d}, \dots, X_0\}$ und $\{Y_1, Y_2, \dots\}$ sind orthogonal, d.h. paarweise unkorreliert.

Es seien $n+d$ Werte, etwa $X_{1-d}, X_{2-d}, \dots, X_n$ von $\{X_j\}$, d.h. n Werte Y_1, \dots, Y_n von $\{Y_j\}$ beobachtet worden.

Gesucht: $P_{\mathcal{M}_n} X_{n+h} = P_{[\{X_{1-d}, \dots, X_n\}]} X_{n+h}$ ($h = 1, 2, \dots$).

$$\text{Setze } P_n Y_{n+h} := P_{[\{Y_1, \dots, Y_n\}]} Y_{n+h}, \quad \hat{Y}_{n+1} = P_n Y_{n+1}.$$

$$\text{Da } \mathcal{M}_n = [\{X_{1-d}, \dots, X_0; Y_1, \dots, Y_n\}]$$

$$\text{und } [\{X_{1-d}, \dots, X_0\}] \perp [\{Y_1, \dots, Y_n\}],$$

erhält man:

$$(10.6) \quad P_{\mathcal{M}_n} Y_{n+h} = P_{\mathcal{M}_0} Y_{n+h} + P_n Y_{n+h} = P_n Y_{n+h}.$$

Eine Anwendung von (10.6) auf die Gleichung (10.5) liefert:

$$(10.7) \quad P_{\mathcal{M}_n} X_{n+h} \stackrel{(10.5)}{=} P_{\mathcal{M}_n} \left(Y_{n+h} - \sum_{j=1}^d \binom{d}{j} (-1)^j X_{n+h-j} \right) \stackrel{(10.6)}{=} P_n Y_{n+h} - \sum_{j=1}^d \binom{d}{j} (-1)^j P_{\mathcal{M}_n} X_{n+h-j}.$$

Da die Vorhersagen $P_n Y_{n+h}$ der ARMA(p, q)-Reihe $\{Y_j\}$ gemäß § 7 rekursiv bestimmt werden können, lassen sich die Vorhersagen $P_{\mathcal{M}_n} X_{n+1}, P_{\mathcal{M}_n} X_{n+2}, \dots$ also gemäß (10.7) ebenfalls rekursiv berechnen. Man beachte: $P_{\mathcal{M}_n} X_{n+1-j} = X_{n+1-j}$ ($j = 1, \dots, d$).

Mit $X_{k+1}^* = P_{\mathcal{M}_k} X_{k+1}$ liefern (10.5) und (10.7):

$$X_{k+1} - X_{k+1}^* = Y_{k+1} - \hat{Y}_{k+1}, \quad k = 0, 1, \dots.$$

Folglich für $n > r = \max(p, q)$ und $h \geq 1$ (vgl. (7.8)/(7.13)):

$$(10.8) \quad P_n Y_{n+h} = \sum_{j=1}^p a_j P_n Y_{n+h-j} + \sum_{j=h}^q d_{n+h-1,j} (X_{n+h-j} - X_{n+h-j}^*) .$$

Mit $a^*(z) = (1-z)^d a(z) = 1 - a_1^* z - \dots - a_{p+d}^* z^{p+d}$ liefern (10.6)–(10.8):

$$(10.9) \quad P_{M_n} X_{n+h} = \sum_{j=1}^{p+d} a_j^* P_{M_n} X_{n+h-j} + \sum_{j=h}^q d_{n+h-1,j} (X_{n+h-j} - X_{n+h-j}^*) ,$$

analog zu (7.8)/(7.13) für die h -Schritt-Vorhersagen von ARMA(p, q)-Reihen.

Zum Vorhersagefehler: vgl. Brockwell & Davis (1991), Formeln (9.5.6) und (9.5.7).

Abschließend noch einige Bemerkungen zu

SARIMA-(saisonale ARIMA-)Zeitreihen:

Statt des klassischen Modells $X_j = m_j + s_j + Y_j$, $j \in \mathbb{Z}$ mit deterministischen Trend- und Saisonkomponenten m_j und s_j betrachtet man die trendbereinigte Zeitreihe mit zufälliger Saisonkomponente, z.B. Monatsdaten über verschiedene Jahre erhoben:

		Monat			
		1	2	...	12
Jahr	1	X_1	X_2	...	X_{12}
	2	X_{13}	X_{14}	...	X_{24}
	3	X_{15}	X_{26}	...	X_{36}
	:	:	:		:
	r	$X_{1+12(r-1)}$	$X_{2+12(r-1)}$...	$X_{12+12(r-1)}$

Modellierung, z.B. für Monat $k = 1, \dots, 12$:

$$(10.10) \quad \begin{cases} X_{k+12j} - A_1 X_{k+12(j-1)} - \dots - a_P X_{k+12(j-P)} \\ = U_{k+12j} + B_1 U_{k+12(j-1)} + \dots + B_Q U_{k+12(j-Q)} \end{cases}$$

mit $\{U_{k+12j}\}_{j \in \mathbb{Z}} \stackrel{\mathcal{D}}{\sim} WN(0, \sigma_U^2)$, d.h., man modelliert dasselbe ARMA(P, Q)-Modell für die “Zwischenjahreswerte”.

Man beachte, dass i.A. $E U_j U_{j+h} \neq 0$, falls $h \neq 12$.

Mit $A(z) = 1 - A_1 z - \dots - A_P z^P$, $B(z) = 1 + B_1 z + \dots + B_Q z^Q$, $z \in \mathbb{C}$, und dem Backward-Shift-Operator B^{12} gilt:

$$(10.10') \quad A(B^{12}) X_j = B(B^{12}) U_j, \quad j \in \mathbb{Z},$$

wobei $\{U_{k+12j}\} \stackrel{\mathcal{D}}{\sim} WN(0, \sigma_U^2)$.

Zur Modellierung der Abhängigkeiten der 12 verschiedenen „Zwischenjahresreihen“ wähle man z.B. ein ARMA(p, q)-Modell für die Folge $\{U_j\}_{j \in \mathbb{Z}}$, d.h.

$$(10.11) \quad a(B)U_j = b(B)e_j, \quad j \in \mathbb{Z},$$

mit $a(z) = 1 - a_1 z - \dots - a_p z^p$, $b(z) = 1 + b_1 z + \dots + b_q z^q$, $\{e_j\} \stackrel{\mathcal{D}}{\sim} WN(0, \sigma^2)$.

Man beachte, dass i.A.

$$E U_j U_{j+h} \neq 0 \quad \forall j, h \quad \text{aber}$$

$$E U_j U_{j+12h} \quad \text{„klein“}.$$

Eine Kombination von (10.10) und (10.11) und Zulassen vorheriger Differenzenbildung liefert:

Definition 10.2. (*SARIMA*(p, d, q) \times (P, D, Q_s -Reihe)) Für $d, D \in \mathbb{N}_0$ heißt $\{X_j\}_{j \in \mathbb{Z}}$ saisonale ARIMA(p, d, q) \times (P, D, Q_s -Reihe) mit Periode s , falls die Reihe $\{Y_j\}_{j \in \mathbb{Z}}$ mit $Y_j = (1 - B^1)^d (1 - B^s)^D X_j$ eine kausale ARMA(p, q)-Reihe bildet, d.h.

$$a(B^1)A(B^s)Y_j = b(B^1)B(B^s)e_j, \quad j \in \mathbb{Z},$$

wobei $\{e_j\} \stackrel{\mathcal{D}}{\sim} WN(0, \sigma^2)$ und $a(z) = 1 - a_1 z - \dots - a_p z^p$, $a_p \neq 0$, $A(z) = 1 - A_1 z - \dots - A_P z^P$, $A_P \neq 0$, $b(z) = 1 + b_1 z + \dots + b_q z^q$, $b_q \neq 0$, $B(z) = 1 + B_1 z + \dots + B_Q z^Q$, $B_Q \neq 0$.

Bemerkung 10.2.

- a) $\{Y_j\}$ kausal $\implies a(z) \neq 0 \neq A(z)$ ($|z| \leq 1$);
- b) In Anwendungen: $D \leq 1$ und $P, Q \leq 3$.

Schritte zur Anpassung eines SARIMA-Modells:

- 1) Finde d, D so, dass die differenzierte Reihe

$$Y_j = (1 - B)^d (1 - B^s)^D X_j, \quad j \in \mathbb{Z},$$

ein stationäres Verhalten zeigt (s.o.).

- 2) Finde P, Q so, dass die geschätzten Autokorrelationen $\hat{\rho}(sh)$, $h = 1, 2, \dots$, von $\{Y_j\}$ zum „Lag h “ zu denen einer ARMA(P, Q)-Reihe vergleichbar sind.
- 3) Finde p, q so, dass $\hat{\rho}(1), \dots, \hat{\rho}(s-1)$ zu den Autokorrelationen einer ARMA(p, q)-Reihe vergleichbar sind.

Zu weiteren Einzelheiten und Beispielen vgl. Brockwell & Davis (1991), § 10.6.